Práctica 05. Índices y optimizacion de las bases de datos

Adminstración y Diseño de Bases de Datos

Cheuk Kelly Ng Pante (alu0101364544@ull.edu.es)

29 de noviembre de 2023

Índice general

1. Restauracion de la base de datos *postgres_air*

Para la restauración de la base de datos se ha optado por usar la base de datos *postgres_air.backup*. Antes de restaurar la base de datos, hay que crear la base de datos *postgres_air*, primero entramos en la consola de postgres y luego creamos la base de datos con la siguiente sentencia:

```
CREATE DATABASE postgres_air;
```

Una vez creada la base de datos, la restauramos con el siguiente comando:

```
pg_restore -x --no-owner -U postgres -d postgres_air ./postgres_air.backup
```

2. Incluir sentencias SQL para la creación de los índices

Tenemos las siguientes sentencias SQL:

```
SET search_path TO postgres_air;
CREATE INDEX flight_departure_airport ON
flight(departure_airport);
CREATE INDEX flight_scheduled_departure ON postgres_air.flight
(scheduled_departure);
CREATE INDEX flight_update_ts ON postgres_air.flight (update_ts);
CREATE INDEX booking_leg_booking_id ON postgres_air.booking_leg
(booking_id);
CREATE INDEX booking_leg_update_ts ON postgres_air.booking_leg
(update_ts);
CREATE INDEX account_last_name
        ON account (last_name);
```

Figura 2.1: Sentencias SQL

Lo que hacen estas sentencias es crear índices en las tablas y atributos más consultados. De estas manera el rendimiento de la base de datos mejora sustancialmente.

Aqui una captura de pantalla de la ejecución de las sentencias SQL:

```
postgres_air=# \i create_index.sql
SET
CREATE INDEX
CREATE INDEX
CREATE INDEX
CREATE INDEX
CREATE INDEX
CREATE INDEX
```

Figura 2.2: Ejecución de las sentencias SQL

3. Identifique las tablas principales y sus principales elementos

Las tablas principales son las siguientes:

- **accounts:** Contiene información de las cuentas de los usuarios.

  account_id: Identificador de la cuenta, de tipo *INTEGER*.

  login: Nombre de usuario, de tipo *TEXT*.

  first_name Nombre del usuario, de tipo *TEXT*.

  last_name Apellido del usuario, de tipo *TEXT*.

  frequent_flyer_id Identificador del viajero frecuente, de tipo *INTEGER*.

  update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

- **aircraft:** Contiene información de los aviones.

  model Modelo del avión, de tipo *TEXT*.

  range Rango del avión, de tipo *NUMERIC*.

  class Clase del avión, de tipo *INTEGER*.

  velocity Velocidad del avión, de tipo *NUMERIC*.

  code Código del avión, de tipo *TEXT*.

- **airport:** Contiene información de los aeropuertos.

  airport_code Código del aeropuerto, de tipo *CHARACTER(3)*.

  airport_name Nombre del aeropuerto, de tipo *TEXT*.

  city Ciudad del aeropuerto, de tipo *TEXT*.

  airport_tz Zona horaria del aeropuerto, de tipo *TEXT*.

  continent Continente del aeropuerto, de tipo *TEXT*.

  iso_country Código del país del aeropuerto, de tipo *TEXT*.

  iso_region Código de la región del aeropuerto, de tipo *TEXT*.

  intnl Si el aeropuerto es internacional o no, de tipo *BOOLEAN*.

  update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

- **boarding_pass:** Contiene información de las tarjetas de embarque.

  pass_id Identificador de la tarjeta de embarque, de tipo *INTEGER*.

  passenger_id Identificador del pasajero, de tipo *BIGINT*.

  booking_leg_id Identificador de la reserva del vuelo, de tipo *BIGINT*.

  seat Asiento del pasajero, de tipo *TEXT*.

boarding_time Fecha de embarque, de tipo *TIMESTAMP WITH TIME ZONE*.

precheck Si el pasajero ha hecho el check-in o no, de tipo *BOOLEAN*.

update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

- **booking:** Contiene información de las reservas.

  booking_id Identificador de la reserva, de tipo *BIGINT*.

  booking_ref Referencia de la reserva, de tipo *TEXT*.

  booking_name Nombre de la reserva, de tipo *TEXT*.

  account_id Identificador de la cuenta, de tipo *INTEGER*.

  email Correo electrónico, de tipo *TEXT*.

  phone Teléfono, de tipo *TEXT*.

  update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

  price Precio de la reserva, de tipo *NUMERIC*.

- **booking_leg:** Contiene información de las reservas de los vuelos.

  booking_leg_id Identificador de la reserva del vuelo, de tipo *INTEGER*.

  booking_id Identificador de la reserva, de tipo *INTEGER*.

  flight_id Identificador del vuelo, de tipo *INTEGER*.

  leg_num Número de la reserva del vuelo, de tipo *INTEGER*.

  is_returning Si el vuelo es de vuelta o no, de tipo *BOOLEAN*.

  update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

- **flight:** Contiene información de los vuelos.

  flight_id Identificador del vuelo, de tipo *INTEGER*.

  flight_no Número del vuelo, de tipo *TEXT*.

  scheduled_departure Fecha de salida programada, tipo *TIMESTAMP WITH TIME ZONE*.

  scheduled_arrival Fecha de llegada programada, de tipo *TIMESTAMP WITH TIME ZONE*.

  departure_airport Código del aeropuerto de salida, de tipo *CHARACTER(3)*.

  arrival_airport Código del aeropuerto de llegada, de tipo *CHARACTER(3)*.

  status Estado del vuelo, de tipo *TEXT*.

  aircraft_code Código del avión, de tipo *CHARACTER(3)*.

  actual_departure Fecha de salida actual, de tipo *TIMESTAMP WITH TIME ZONE*.

  actual_arrival Fecha de llegada actual, de tipo *TIMESTAMP WITH TIME ZONE*.

  update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

- **frequent_flyer:** Contiene información de los viajeros frecuentes.

  frequent_flyer_id Identificador del viajero frecuente, de tipo *INTEGER*.

  first_name Nombre del viajero frecuente, de tipo *TEXT*.

  last_name Apellido del viajero frecuente, de tipo *TEXT*.

  title Título del viajero frecuente, de tipo *TEXT*.

  card_num Número de la tarjeta del viajero frecuente, de tipo *TEXT*.

  level Nivel del viajero frecuente, de tipo *INTEGER*.

  award_points Puntos del viajero frecuente, de tipo *INTEGER*.

  email Correo electrónico del viajero frecuente, de tipo *TEXT*.

  phone Teléfono del viajero frecuente, de tipo *TEXT*.

  update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

- **passenger:** Contiene información de los pasajeros.

  passenger_id Identificador del pasajero, de tipo *INTEGER*.

  booking_id Identificador de la reserva, de tipo *INTEGER*.

  booking_ref Referencia de la reserva, de tipo *TEXT*.

  passenger_no Número del pasajero, de tipo *INTEGER*.

  first_name Nombre del pasajero, de tipo *TEXT*.

  last_name Apellido del pasajero, de tipo *TEXT*.

  account_id Identificador de la cuenta, de tipo *INTEGER*.

  update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

  age Edad del pasajero, de tipo *INTEGER*.

- **phone:** Contiene información de los teléfonos.

  phone_id Identificador del teléfono, de tipo *INTEGER*.

  account_id Identificador de la cuenta, de tipo *INTEGER*.

  phone Teléfono, de tipo *TEXT*.

  phone_type Tipo de teléfono, de tipo *TEXT*.

  primary_phone Si es el teléfono principal o no, de tipo *BOOLEAN*.

  update_ts Fecha de actualización, de tipo *TIMESTAMP WITH TIME ZONE*.

4. Diagrama Entidad-Relación

5. Realizar la siguiente consulta

```
SELECT flight_id, scheduled_departure
FROM flight f
JOIN airport a
ON departure_airport=airport_code
AND iso_country='US'
```

5.1. Utilizar *EXPLAIN* para obtener el plan de consulta

```
postgres_air=# EXPLAIN SELECT flight_id, scheduled_departure
FROM flight f
JOIN airport a
ON departure_airport=airport_code
AND iso_country='US';
                                QUERY PLAN
---------------------------------------------------------------------------
 Hash Join  (cost=20.09..17223.60 rows=144636 width=12)
   Hash Cond: (f.departure_airport = a.airport_code)
   ->  Seq Scan on flight f  (cost=0.00..15398.76 rows=683176 width=16)
   ->  Hash  (cost=18.33..18.33 rows=141 width=4)
         ->  Seq Scan on airport a  (cost=0.00..18.33 rows=141 width=4)
               Filter: (iso_country = 'US'::text)
(6 rows)
```

Figura 5.1: Consulta con *EXPLAIN*

5.2. Obtener información de la consulta *EXPLAIN*

- **Costo total de la consulta:** 17223.60 unidades.
- **Costo de configuración:** 20.09 unidades.
- **Cantidad de filas que se devolverán:** 144636 filas.
- **Cantidad de filas estimadas:** 683176 filas.

5.3. Repetir la consulta con *EXPLAIN* con un limite de 15 registros

```
postgres_air=# EXPLAIN SELECT flight_id, scheduled_departure
FROM flight f
JOIN airport a
ON departure_airport=airport_code
AND iso_country='US'
LIMIT 15;
                                        QUERY PLAN
-------------------------------------------------------------------------------------------------
 Limit  (cost=0.29..3.67 rows=15 width=12)
   ->  Nested Loop  (cost=0.29..32658.60 rows=144636 width=12)
         ->  Seq Scan on flight f  (cost=0.00..15398.76 rows=683176 width=16)
         ->  Memoize  (cost=0.29..0.31 rows=1 width=4)
               Cache Key: f.departure_airport
               Cache Mode: logical
               ->  Index Scan using airport_pkey on airport a  (cost=0.28..0.30 rows=1 width=4)
                     Index Cond: (airport_code = f.departure_airport)
                     Filter: (iso_country = 'US'::text)
(9 rows)
```

Figura 5.2: Consulta con *EXPLAIN* y límite de 15 registros

5.4. Obtener información de la consulta *EXPLAIN* con un limite de 15 registros

Hay una reducción del costo abismal. Hay en total 2 pasos principales, que son dos los dos Merges. El segundo de esto se subdivide en otros dos en donde consulta los índices previamente creados.

- **Costo del paso limitante:** 3.67 unidades.
- **Costo de configuración:** 0.29 unidades.
- **Cantidad de filas que se devolverán:** 15 filas.
- **Cantidad de filas estimadas:** 144636 filas.

6. Realizar la siguiente consulta similar a la anterior

```
SELECT flight_id, scheduled_departure
FROM flight f
JOIN airport a
ON departure_airport=airport_code
AND iso_country='CZ'
```

Figura 6.1: Consulta con *EXPLAIN*

6.1. Utilizar *EXPLAIN* para obtener el plan de consulta

```
postgres_air=# EXPLAIN SELECT flight_id, scheduled_departure
FROM flight f
JOIN airport a
ON departure_airport=airport_code
AND iso_country='CZ';
                                        QUERY PLAN
-------------------------------------------------------------------------------------------------------
 Nested Loop  (cost=12.42..2964.72 rows=1026 width=12)
   ->  Seq Scan on airport a  (cost=0.00..18.33 rows=1 width=4)
         Filter: (iso_country = 'CZ'::text)
   ->  Bitmap Heap Scan on flight f  (cost=12.42..2936.08 rows=1032 width=16)
         Recheck Cond: (departure_airport = a.airport_code)
         ->  Bitmap Index Scan on flight_departure_airport  (cost=0.00..12.16 rows=1032 width=0)
               Index Cond: (departure_airport = a.airport_code)
(7 rows)
```

Figura 6.2: Consulta con *EXPLAIN*

6.2. Comparar resultados con la consulta anterior

Esta consulta tiene un bajo costo, para no haber limitado la consulta de ninguna manera.

6.3. Diferencia de rendimiento

El principal motivo de que esta consulta sea más ligera se debe precisamente a que sus operaciones son más sencillas de usar, pues no realiza grandes joins como antes, y que además devuelve muchas menos filas.

7. Comparación de consultas

```
SELECT flight_id
      ,departure_airport
      ,arrival_airport
FROM flight
WHERE scheduled_arrival BETWEEN
'2020-10-14' AND '2020-10-15';
```

A

```
SELECT flight_id
      ,departure_airport
      ,arrival_airport
FROM flight
WHERE scheduled_arrival:: date='2020-
10-14';
```

B

7.1. Construir índices

Para construir los índices, se han usado las siguientes sentencias SQL:

- Consulta A:

```
CREATE INDEX flight_idx_brin ON flight USING BRIN(flight_id);
```

- Consulta B:

```
CREATE INDEX flight_idx_hash ON flight USING hash(flight_id);
```

7.2. Evaluación del rendimiento

Al realizar la consulta sin índices de la consulta A y B obtenemos lo siguiente:

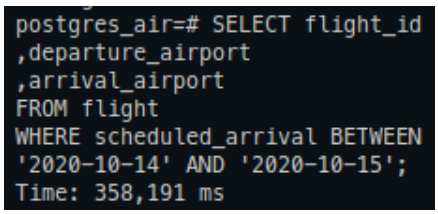

(a) Consulta A sin índice.

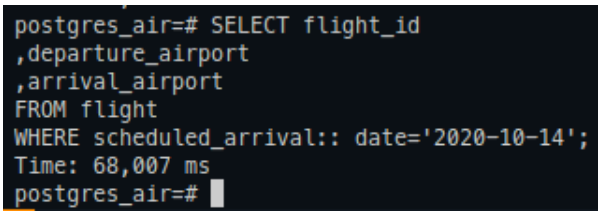

(b) Consulta B sin índice.

Figura 7.1: Consultas de ambas consultas sin índices

Ahora, al realizar la consulta con índices de la consulta A y B obtenemos lo siguiente:

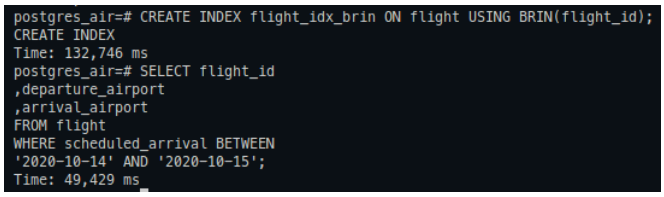

(a) Consulta A con índice.

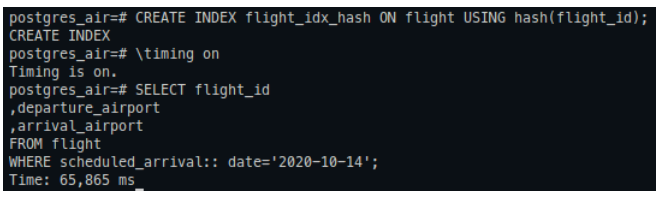

(b) Consulta B con índice.

Figura 7.2: Consultas de ambas consultas con índices

	Consulta A	**Consulta B**
Sin índice	358,191ms	68,007
Con índice	49,429ms	65,865

Cuadro 7.1: Tabla de resultados

Con los resultados obtenidos, con se observa en la tabla 7.1, podemos ver que al realizar un índice en la consulta A el rendimiento mejora considerablemente, mientras que en la consulta B no mejora tanto ya que la consulta de por sí era bastante rápida.

Para el caso de la consulta A, se usa un índice del tipo *BRIN* ya que es un índice que se usa para tablas muy grandes, y en este caso la tabla *flight* tiene 144636 filas. Para el caso de la consulta B, se usa un índice del tipo *hash* por tratarse de una comparacion de igualdad simple.